基于大语言模型与因果推理的 Concept Bottleneck Model 研究调研与后续规划

0. 报告目标

本报告围绕两篇近期 Concept Bottleneck Model（CBM）方向论文展开：

1. Bayesian Concept Bottleneck Models with LLM Priors（BC-LLM）
2. Causally Reliable Concept Bottleneck Models（C²BM）

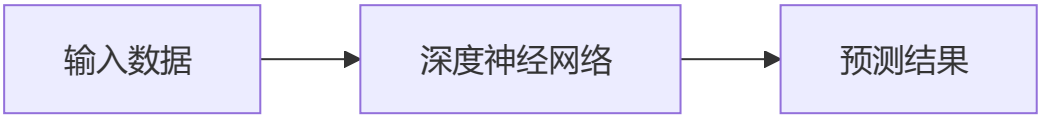
主要目标：

- 理解两篇论文解决的核心科学问题；
- 梳理完整科研流程，包括问题提出、方法设计、实验验证；
- 分析两篇论文之间的联系和不足；
- 探索结合 LLM、Bayesian 推理以及因果建模的潜在研究方向。

1. 研究背景

1.1 黑盒深度学习模型问题

传统深度学习：



优势：

- 强大的预测能力；
- 良好的任务性能。

不足：

- 缺少解释能力；
- 难以进行人工干预；
- 容易学习数据中的虚假相关。

因此，在医疗、科学发现、高风险决策领域，需要：

- 可解释；
- 可验证；
- 可干预；
- 具有因果可靠性的模型。

2. Concept Bottleneck Model 基础

2.1 CBM思想

Concept Bottleneck Model 将模型推理过程拆分：



数学形式：

$$P(Y, V \| X) = P(Y \| V) P(V \| X)$$

其中：

- X：输入数据
- V：人类可理解概念
- Y：预测任务

2.2 CBM优势

相比黑盒模型：

CBM允许：

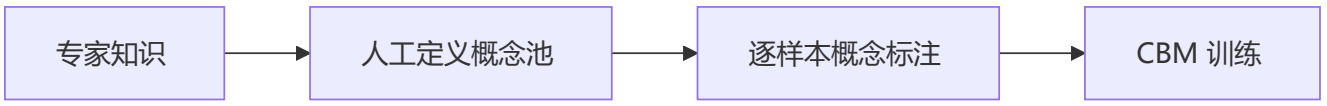
1. 查看模型依据的概念；
2. 修改概念进行人工干预；
3. 分析模型错误来源。

---

3. 当前CBM存在的问题

3.1 概念发现问题

传统流程：



问题：

- 依赖专家；
- 成本高；
- 难以扩展；
- 可能遗漏关键概念。

对应论文：

BC-LLM

3.2 因果可靠性问题

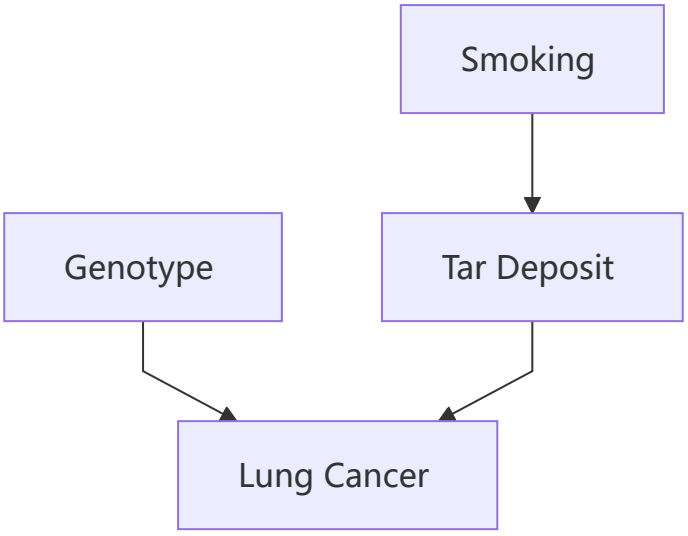
传统CBM：

$Y = f(V_1, V_2, ..., V_C)$

假设：

所有概念直接影响预测。

但是现实（以 C²BM 论文中的肺癌机制为例）：



概念之间具有层级因果关系；目标变量往往由部分概念经中间机制间接决定，而非所有概念均为 Y 的直接原因。

对应论文：

C²BM

4. 论文一：BC-LLM详细分析

4.1 研究问题

核心问题：

> 如何利用LLM自动发现有效概念，同时避免LLM错误概念带来的影响？

作者观点：

LLM可以提供概念先验，但是不能完全信任。

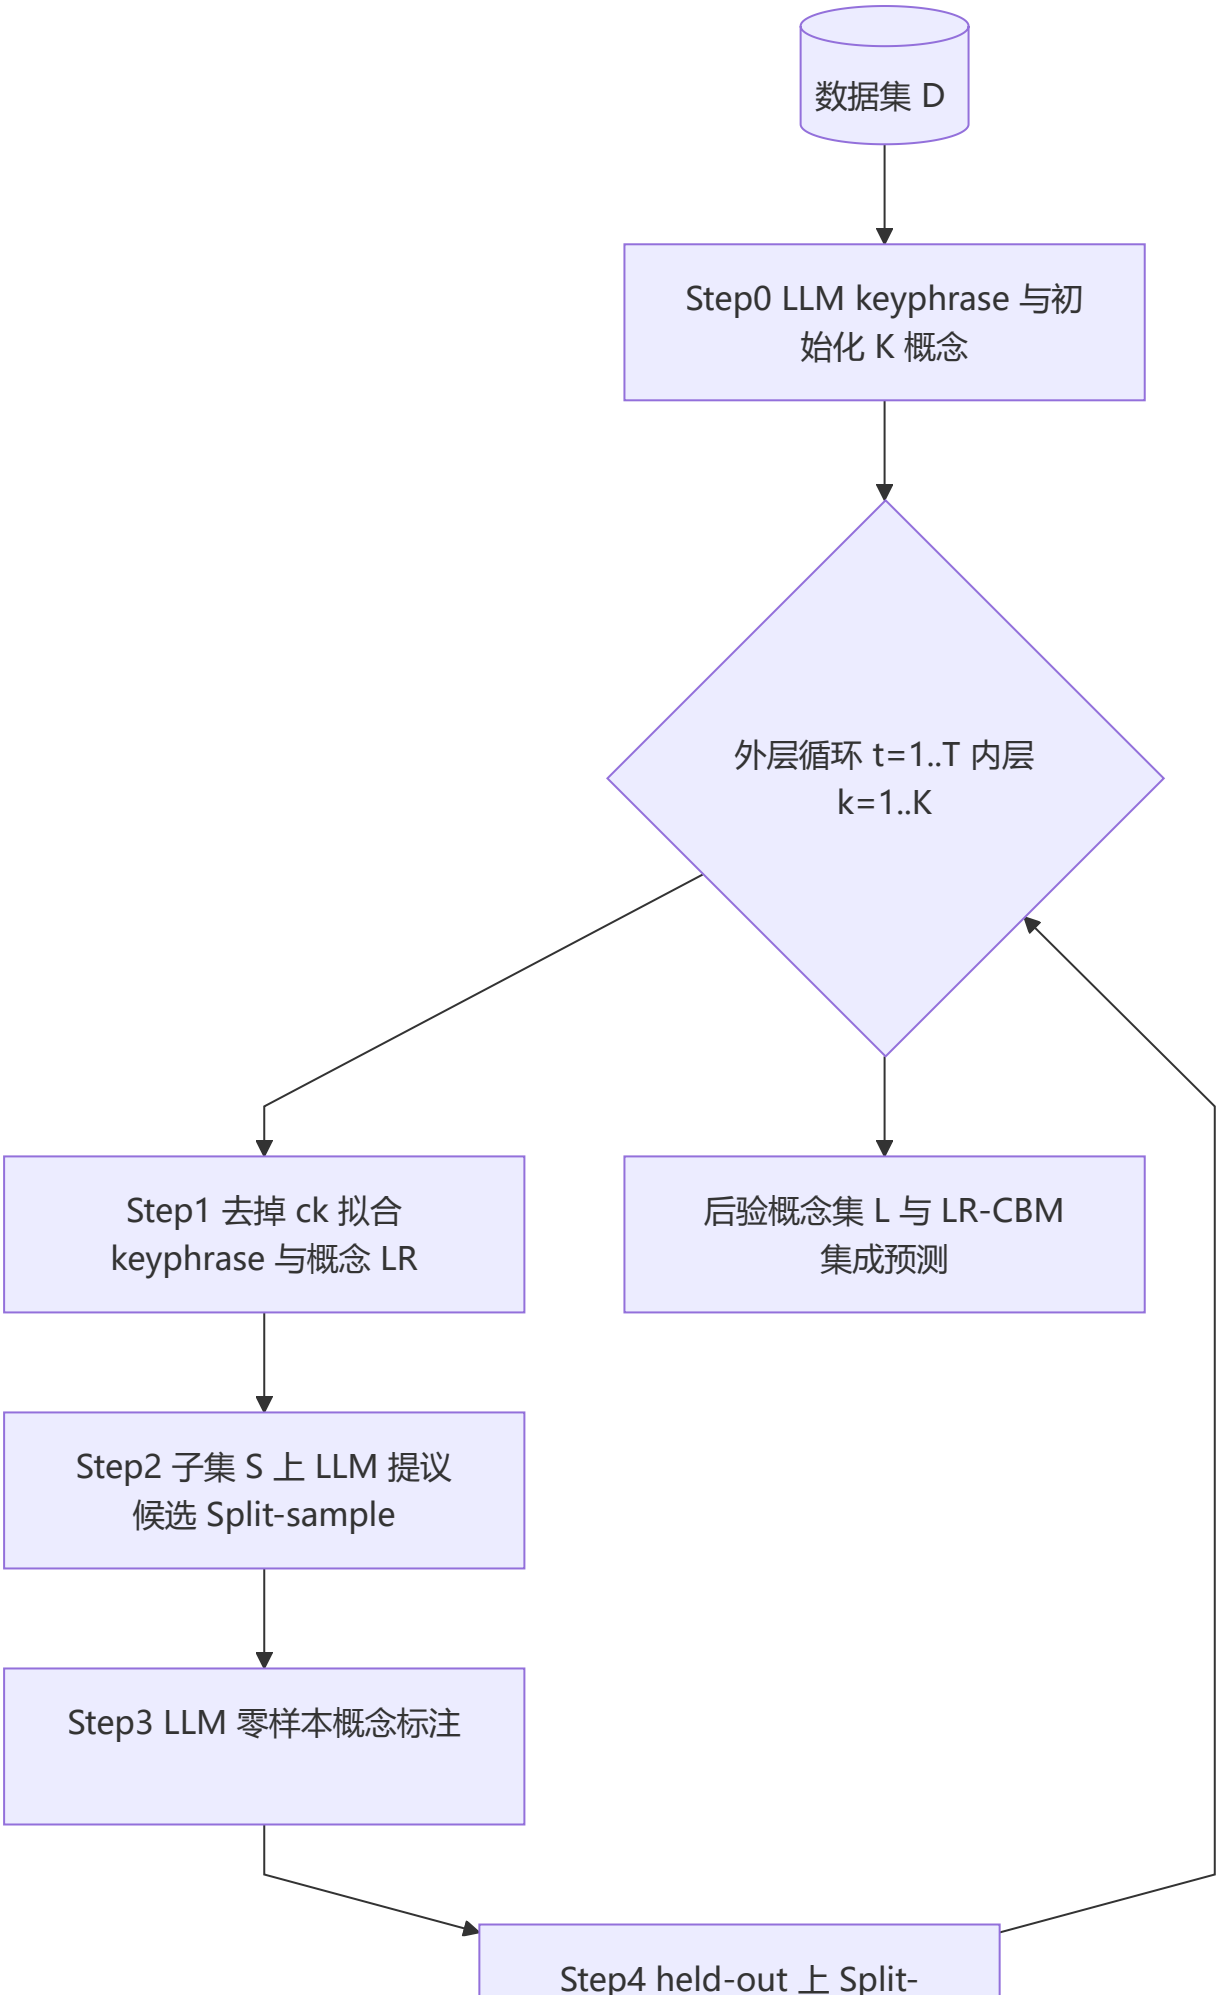
因此（与论文表述一致）：

- **LLM**：keyphrase/概念提议、partial posterior 权重、零样本概念取值 $\phi_c(x)$；
- **Bayesian（Metropolis-within-Gibbs + Split-sample）**：在数据上纠正 LLM 错误，推断 $p(c \mid y, X)$ 并量

化概念不确定性。

4.2 总体框架

BC-LLM 不是“一次性生成概念再训练”的线性流程，而是在 **Metropolis-within-Gibbs** 外层循环中，用 **Split-sample Metropolis** 迭代替换概念集合；LLM 同时承担 **概念提议、部分后验（partial posterior）与零样本概念取值** $\phi_c(x)$，数据在 accept/reject 步骤中纠正 LLM 幻觉。


数据集 D
Step0 LLM keyphrase 与初始化 K 概念
外层循环 t=1..T 内层 k=1..K
Step1 去掉 ck 拟合 keyphrase 与概念 LR
后验概念集 L 与 LR-CBM 集成预测
Step2 子集 S 上 LLM 提议候选 Split-sample
Step3 LLM 零样本概念标注
Step4 held-out 上 Split-

sample 接受拒绝

核心 Bayesian 目标：对概念支撑集 c 推断 $p(c \mid y, X)$；提议分布由 LLM 在 **数据子集** S 上近似 $p(C_k \mid c_{-k}, y_S, X)$，接受率用 **held-out** S^c 上的偏 Bayes factor 校验。

4.3 Concept Discovery 流程（对应论文 Fig.1 / Algorithm 1–3)

Step 0：Keyphrase 提取与初始化

- LLM 从每条观测 x 提取 **keyphrase**（图像：可见属性短语；文本：引用或摘要，如 “diabetes”）。
- 用 keyphrase 的 BoW + 惩罚 LR 拟合 Y，再由 LLM 根据最 predictive 的 keyphrase **生成初始 K 个形式化概念**（如 “Does the patient currently have diabetes?”）并完成首轮标注。

Step 1：去掉当前概念并拟合 keyphrase 模型

- 对索引 k，在保留 c_{-k} 的前提下，用 keyphrase BoW + 已有概念拟合 LR，得到 **与标签/残差最相关的 keyphrase 摘要**，供 Step 2 提示 LLM。

Step 2：LLM 提议候选概念（partial posterior)

- 随机划分 $S \cup S^c$；仅在 S 上让 LLM 提出 M 个替换 c_k 的候选，并给出 partial posterior 权重（Multiple-try Metropolis 可批量提议）。

Step 3：LLM 概念标注

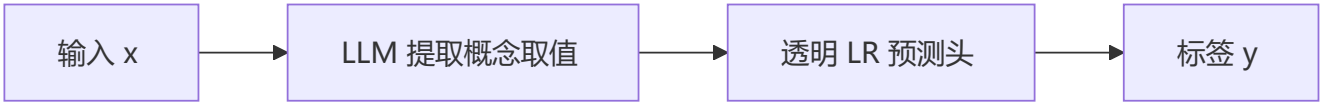
- 对候选概念批量零样本提取 $\phi_c(x)$（硬/可解释取值，避免与标签联合训练造成信息泄漏）。

Step 4：Split-sample 接受 / 拒绝

- 在 S^c 上比较候选与当前概念集的偏后验，按 α 接受或保留原 c_k；重复至得到概念集合的后验样本 L。

预测阶段：透明 CBM（LR）

选定/集成后的概念支撑上，预测由 **稀疏 logistic regression** 完成，而非端到端黑盒概念编码器：



4.4 实验设计

任务：

视觉任务

CUB-birds：在同一 **鸟科（family）** 内做物种分类（37 个子任务；LLM 不知任务为"鸟类"以测试弱先验下的概念搜索）。

目标：

验证是否发现可区分物种的 **硬概念** 并保持可解释 LR-CBM 的精度。

临床文本任务

（1）**模拟结局**的临床笔记分类（Section 4.2）；（2）**真实再入院风险**预测（Section 4.3，PHI 环境、与医院数据团队协作）。

目标：

验证医学场景下的概念发现、可解释性与临床可用性。

OOD 与校准

CUB 等任务上的 **分布外** 测试集；指标含 **Accuracy / AUC / Brier / 预测熵**，检验概念后验与集成 LR 的 **校准** 是否优于 ResNet 等黑盒。

4.5 BC-LLM贡献

优点

1. 自动发现概念；
2. 降低人工概念设计成本；
3. Bayesian提供不确定性。

局限

1. 主要关注概念选择；
2. 没有建模概念之间因果关系；
3. 发现的概念可能仍然只是统计相关。

---

5. 论文二：C²BM详细分析

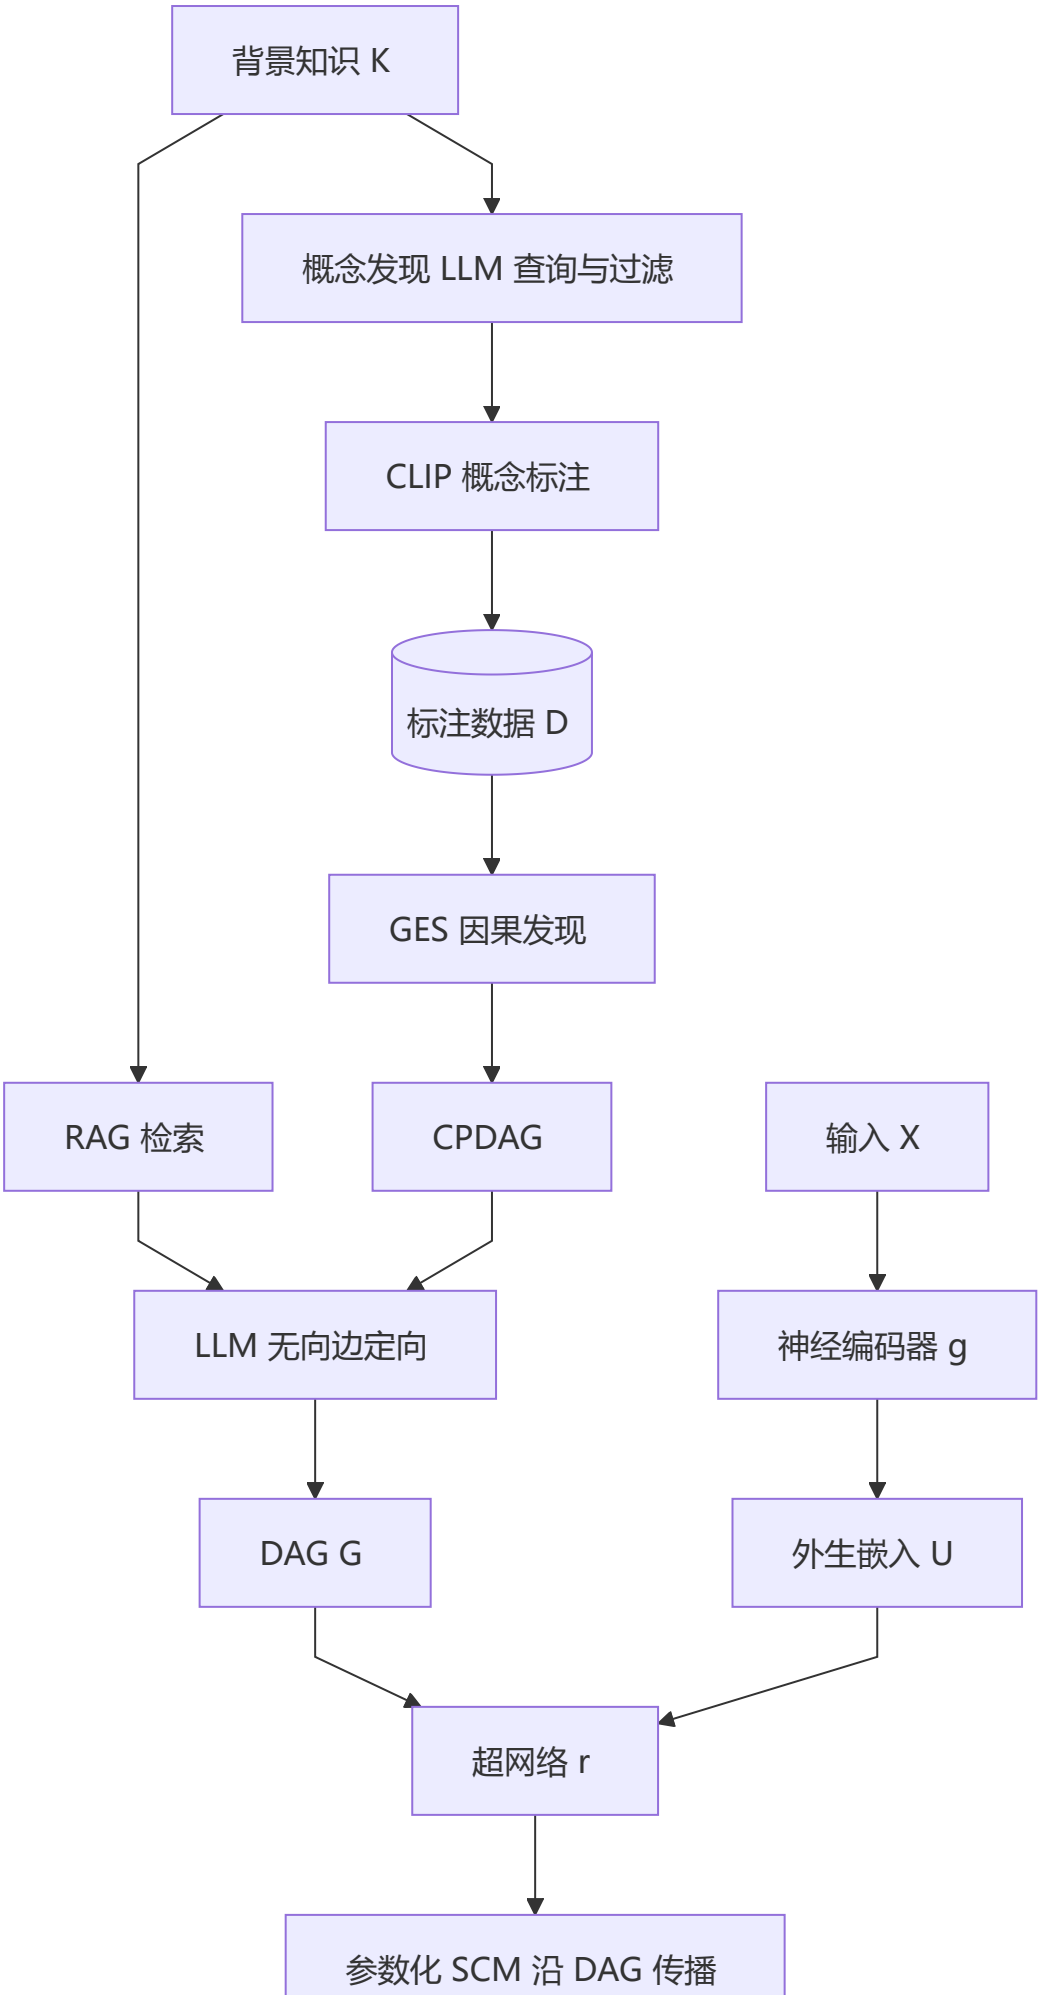
5.1 研究问题

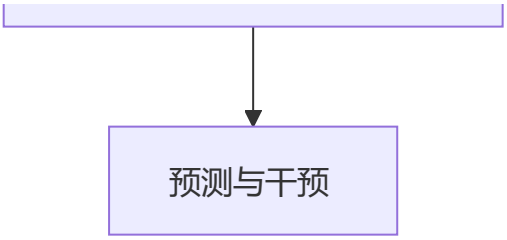
核心：

> 如何让CBM中的概念关系符合真实世界因果机制?

5.2 C²BM总体框架

论文将流程分为 **（i）因果图构建（离线）** 与 **（ii）C²BM 训练与推理** 两大阶段（Fig. 1–2）。推理时信息沿 **因果瓶颈** 从外生变量经 DAG 上的结构方程传播，而非传统 CBM 的“所有概念直接指向 Y”。


背景知识 K
概念发现 LLM 查询与过滤
CLIP 概念标注
标注数据 D
GES 因果发现
RAG 检索
CPDAG
输入 X
LLM 无向边定向
神经编码器 g
DAG G
外生嵌入 U
超网络 r
参数化 SCM 沿 DAG 传播



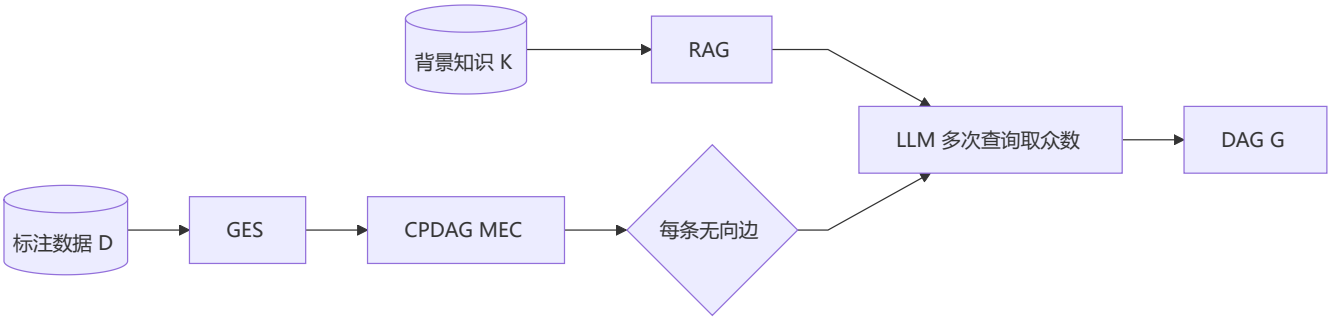
5.3 三个核心模块

Module 1：Concept Discovery & Labeling（Sec. 4.2.1）

- **输入**：任务相关背景知识 **K** + 图像等 **Dx**（可无概念标签）。
- **发现**：沿用 label-free CBM 思路，**LLM 从 K 中列出与任务相关的概念名**，再按简洁性、与目标/彼此区分度、在训练集中可对齐等准则 **过滤** 得到 V。
- **标注**：用 **CLIP** 等 VLM 将样本与概念名对齐，构造 $D = \{(x_i, v_i)\}$ 供后续因果发现与学习监督。

注意：概念发现主要依赖 **K + LLM**，而非 Module 2 中的 GES。

Module 2：Causal Graph Discovery（Sec. 4.2.2）



- **GES** 仅从 **观测数据 D** 得到 **CPDAG**（避免数据不足时强行定向）。
- **LLM + RAG** 针对 CPDAG 中 **每条无向边** 询问因果方向（如 “Does Genotype cause Tar Deposit?”），结合文献证据 **定向或剔除** 伪相关边，得到 **DAG**。

Module 3：C²BM = Encoder + Hypernetwork + Parametric SCM（Sec. 4.1, 4.3）

结构方程（线性可解释形式 + 超网络表达非线性）：

$$V_i = \sum_{V_j \in PA_i} [\theta_{f_i}]_j V_j, \quad \theta_{f_i} = r_i(U_i) = r_i(g(X)_i)$$

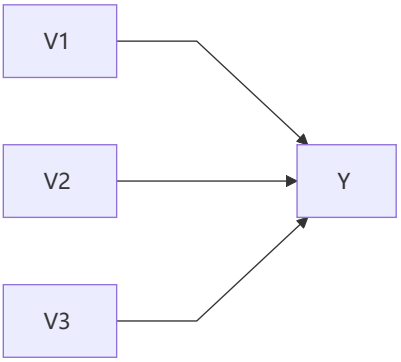
其中：

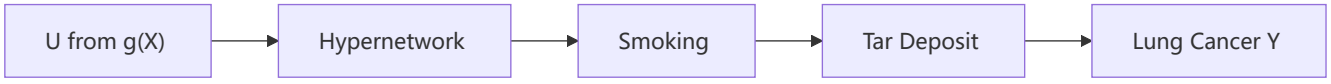
- U：由编码器 $g(X)$ 预测的外生变量（对应 SCM 中未显式建模的扰动）；
- PA_i：DAG **G** 上 V_i 的父节点；
- $r(\cdot)$：超网络据 U 与边集 E 为每条结构方程 **自适应生成参数**；

- 沿 **G** 拓扑顺序传播，得到各概念激活；**Y 通常为 V 中某一汇节点**，支持对任意 V_i 的 **干预** 查询。

训练目标：最大化 $\sum_{(x,v)\in D}\sum_i \log P(V_i \mid PA_i, U_i; \theta_{f_i})$（端到端学习 g 与 r）。

5.4 与传统 CBM 的结构对比





传统 CBM 将概念层 **二部图** 连到 Y；C²BM 用 **DAG 上的 SCM** 约束概念间机制，使干预沿因果方向传播。

5.5 实验验证（论文 Section 5）

1. Accuracy（Sec. 5.1）

与 DNN、标准 CBM/CEM 等比较 **任务精度**，验证引入因果瓶颈 **不牺牲** 表达力。

2. Causal Reliability（Sec. 5.1）

学习到的 **DAG / 机制** 与已知或合成真因果结构的一致性（相对仅关联的 CBM 扩展）。

3. Intervention（Sec. 5.2）

对概念 **do-干预** 后下游预测变化；C²BM 用 **更少干预步数** 达到更高 **干预准确率**。

4. Debiasing（Sec. 5.3）

在含 **虚假相关** 的设置中减轻对 shortcut 的依赖。

5. Fairness（Sec. 5.4）

通过概念干预 **消除** 不当模型行为，满足公平性约束。

5.6 C²BM贡献与不足

贡献：

- 引入因果瓶颈；
- 支持干预推理；
- 提高模型可靠性。

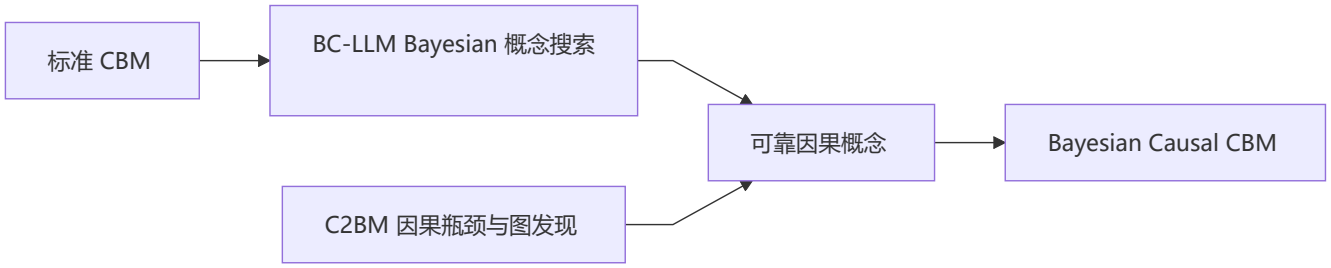
不足：

- 概念发现模块沿用 **label-free CBM + CLIP**，创新主要在 **因果图构建 + C²BM 架构**；
- 因果发现仍受 **观测数据可辨识性** 与 **LLM/RAG 定向质量** 限制；
- 与 BC-LLM 正交：未对概念集合做 **Bayesian 数据驱动搜索**，概念池质量仍影响最终 DAG。

---

6. 两篇论文对比

维度	BC-LLM	C²BM
核心问题	概念集合 c 的数据驱动选择	概念间因果结构与可靠干预
核心方法	Metropolis-within-Gibbs + Split-sample；LLM 提议与标注	GES → CPDAG；RAG + LLM 边定向；超网络 SCM
概念来源	迭代搜索（潜在无穷概念）	背景知识 K + LLM（label-free）+ CLIP 标注
预测头	透明 LR（LLM 提取的概念取值 φ_c(x)）	DAG 上结构方程传播
优势	精度–可解释权衡、概念不确定性量化	因果可靠、干预 / 去偏 / 公平
不足	无概念间因果 DAG	概念发现为流水线组件，非 BC-LLM 式 Bayesian 选概念
结合点	为 C²BM 提供更可靠的概念池	为 BC-LLM 所选概念赋予因果组织方式



---

7. 潜在研究方向

Direction 1：

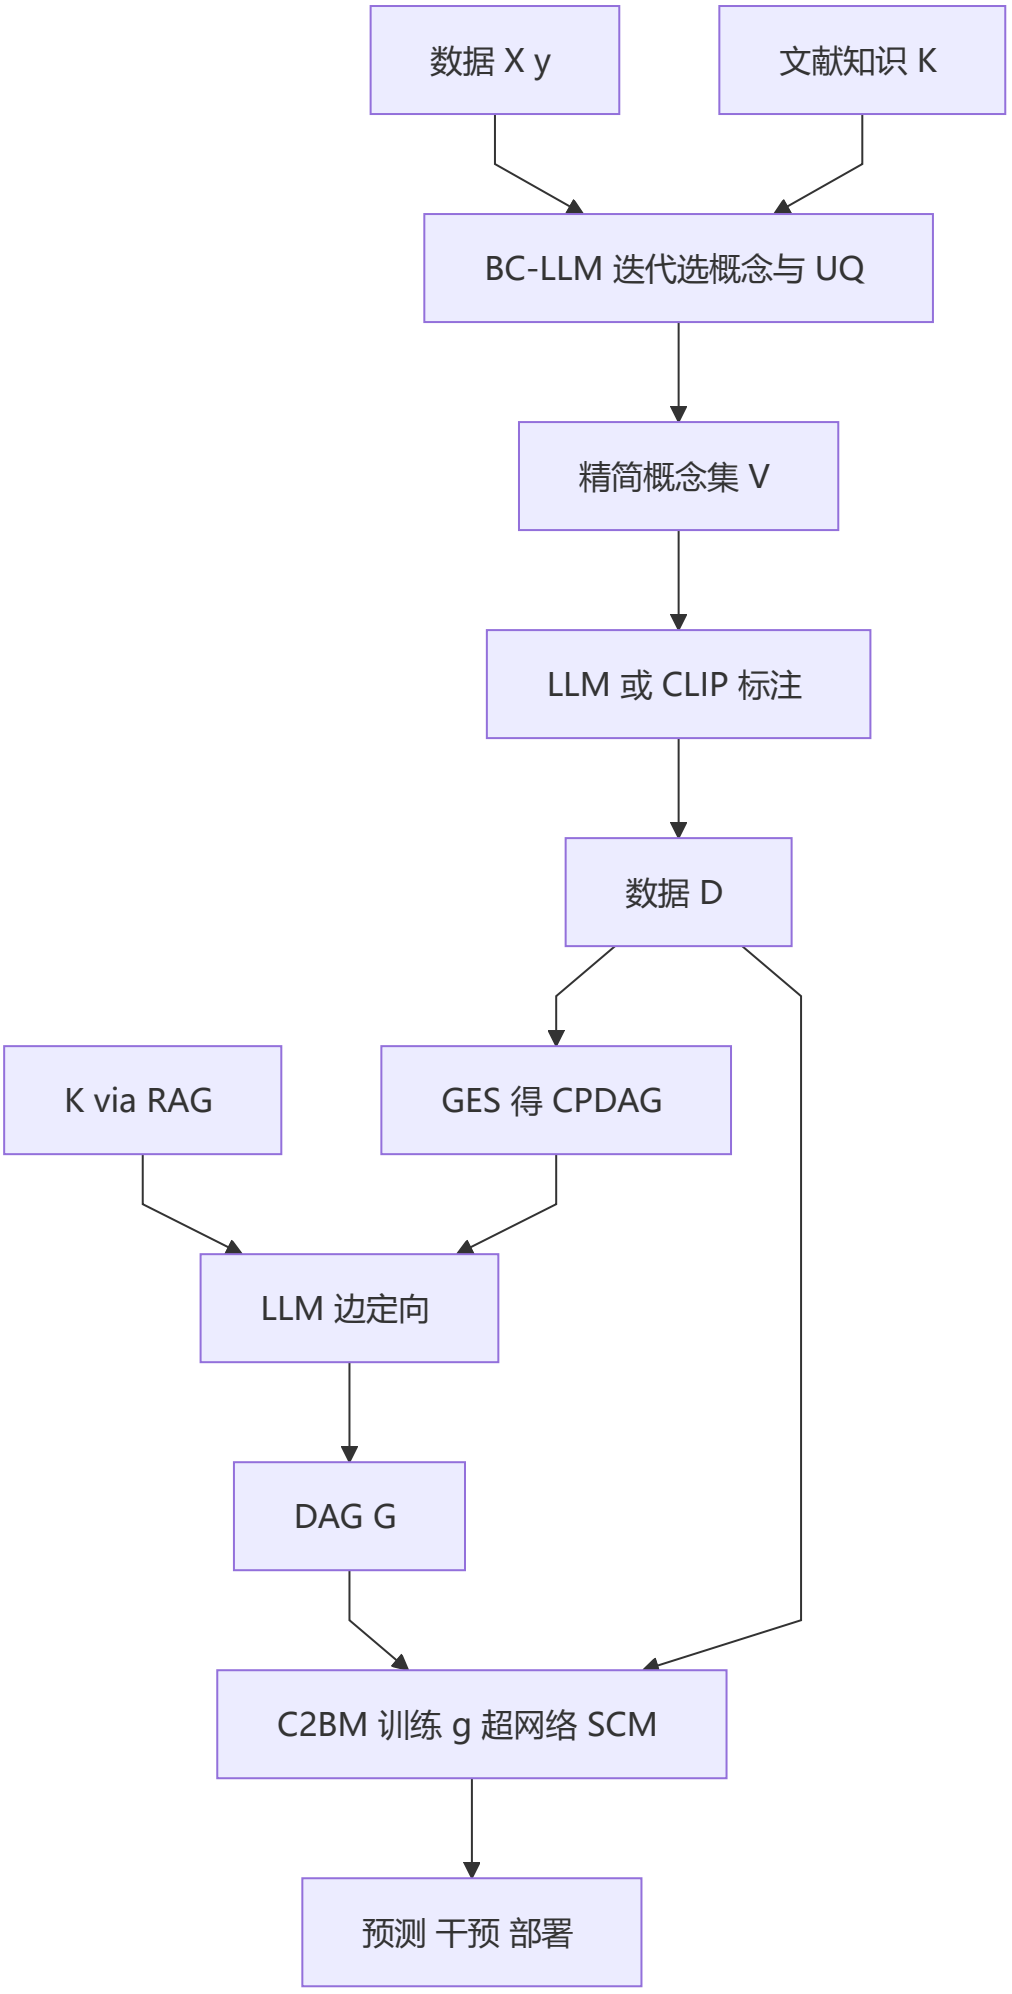
Bayesian Causal Concept Bottleneck Model

目标：

同时解决：

- 概念自动发现；
- 概念可靠性；
- 因果推理。

整体流程（衔接两篇论文能力，非已有单一论文）：


数据 X y
文献知识 K
BC-LLM 迭代选概念与 UQ
精简概念集 V
LLM 或 CLIP 标注
数据 D
K via RAG
GES 得 CPDAG
LLM 边定向
DAG G
C2BM 训练 g 超网络 SCM
预测 干预 部署

Direction 2：

LLM Agent驱动科学概念发现

目标：

利用：

- 文献知识；
- 实验数据；
- 因果分析。

自动提出科学假设。

Direction 3：

Dynamic Causal Concept Updating

研究问题：

随着新知识加入：

如何动态更新：

- Concept
- Causal Graph
- Model

8. 后续研究计划

阶段	具体日期	任务	输出
第 1 周	2026 年 9 月 17 日	粗略阅读 BC-LLM、C²BM 两篇文献的方法论；后续研究计划规划	本调研汇报、研究计划提纲
第 2–3 周	2026 年 9 月 24 日 – 2026 年 10 月 1 日	深入阅读两篇文献（方法 + 实验）；代码复现（BC-LLM / C²BM 核心流程）	精读笔记、复现实验记录
第 4–5 周	2026 年 10 月 8 日 – 2026 年 10 月 15 日	分析融合方向、与导师对齐问题	Research Idea
第 6–7 周	2026 年 10 月 22 日 – 2026 年 10 月 29 日	设计模型框架（如 Bayesian Causal CBM 草案）	Method Draft
第 8–12 周	2026 年 11 月 5 日 – 2026 年 12 月 3 日	实验验证与文稿撰写	论文 / 开题初稿

9. 需要讨论的问题

Question 1

未来研究方向是否应该偏：

- AI方法创新；
- 医学AI；
- AI for Science?

Question 2

Concept discovery是否应该完全依赖LLM?

还是：

结合领域知识库?

Question 3

如何定义和评价：

"可靠的因果概念"?

总结

BC-LLM解决：

> 如何自动找到有效概念。

C²BM解决：

> 如何让概念关系符合因果机制。

未来研究方向：

> 利用LLM进行概念发现，利用Bayesian保证可靠性，利用因果模型实现科学推理。